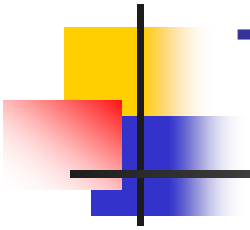


Recuperação de Informação

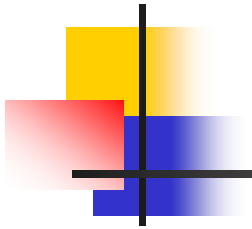
Sistemas para Busca na Web

Marcos Andre Goncalves

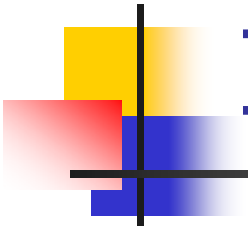


Tópicos

- 1. Introdução:Sistemas de Busca
- Modelos de RI
- 3. Implementação de Sistemas de Busca
  - Coleta
  - Indexação
  - Processamento de Consultas
- 4. Ranking na Web
- 5. Avaliação de Qualidade
- 6. Conclusões



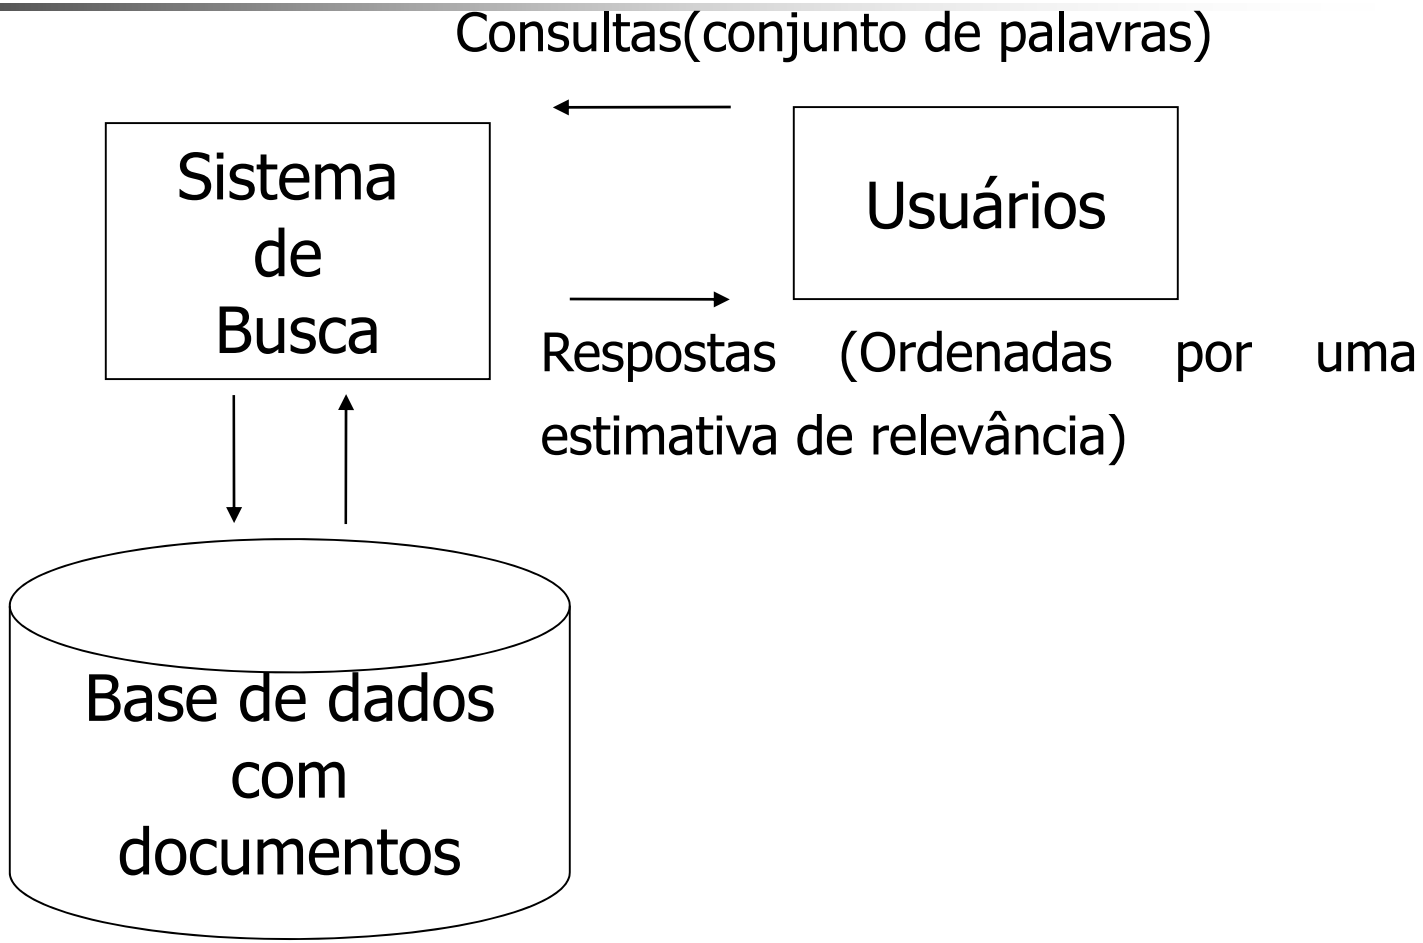
1. Introdução



Introdução

- Neste pequeno tutorial serão discutidos os princípios de funcionamento de máquinas de busca (ou motores de busca) na Web.
- O núcleo destes sistemas é baseado em modelos de uma área conhecida como **recuperação de informação**

Sistemas para Busca em Texto

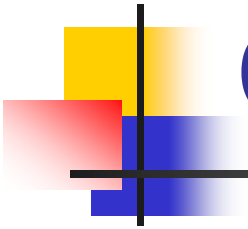


Sistemas de Busca na Web

- Até década de 90, sistemas de busca por documentos eram aplicados dentro de empresas, em bibliotecas, em CDs de jornais e etc..
- Nesta década surgiu a Web, que tornou-se principal foco de atenção para desenvolvedores de sistemas de busca

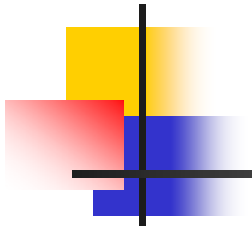
O que mudou com a Web ?

- Novos desafios em termos de escala e de qualidade:
- Necessidade de eficiência:
  - Bases de dados muito grandes . (mais de 300 bilhões de documentos/petabytes)
  - Muitos usuários (Ex. Mais de 150 milhões de consultas/dia no Google).
  - Servidores distribuídos em milhares de máquinas.
- Qualidade:
  - Usuários mais exigentes e menos treinados
  - Muita concorrência
  - Bases de dados mais heterogêneas(grande variação na qualidade, tamanho e tipo de informação contida nos documentos)
  - Muita informação auxiliar disponível sobre documentos



O que mudou com a Web ?

- Uma explosão na quantidade de trabalhos relacionados a sistemas de busca
- Sistemas tornaram-se mais rápidos e melhoraram significativamente a qualidade das respostas providas a seus usuários
- Propaganda na Web, que também usa algoritmos de busca, movimenta dezenas de bilhões de dólares por ano e pode passar a da TV nos próximos anos.



2. Modelagem em RI

Modelos em Recuperação de Informação



- Núcleo de qualquer sistema de busca na Web.
- Utilizados para representar características semânticas dos elementos envolvidos nos sistemas.
- Dois exemplos: Modelo Vetorial e Modelos baseados em Linguagens (Language models)

Modelo Vetorial

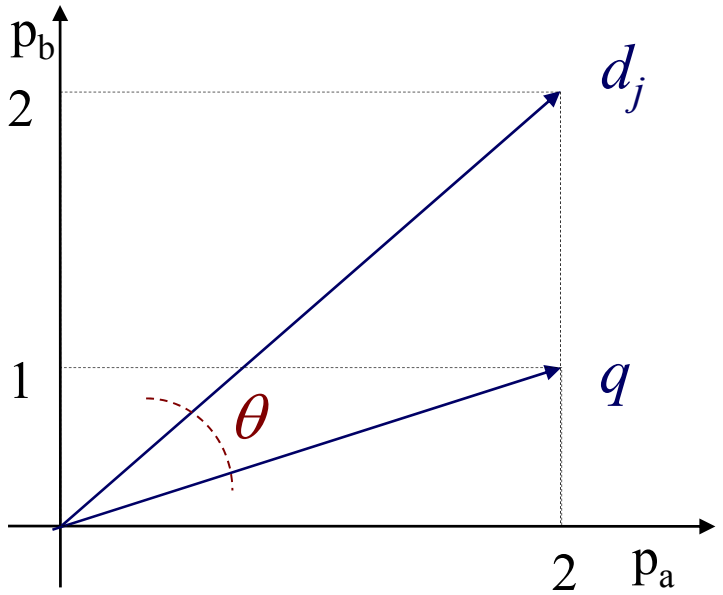
- Proposto em 1968 e continua sendo muito empregado hoje em dia.
- Sucesso reside na eficiência(velocidade) e nos bons resultados obtidos(qualidade).
- Todos os componentes do sistema são vistos como conjuntos de palavras.

Modelo Vetorial

- Componentes do sistema são vistos como vetores cujas coordenadas são determinadas pelas palavras que os descrevem.

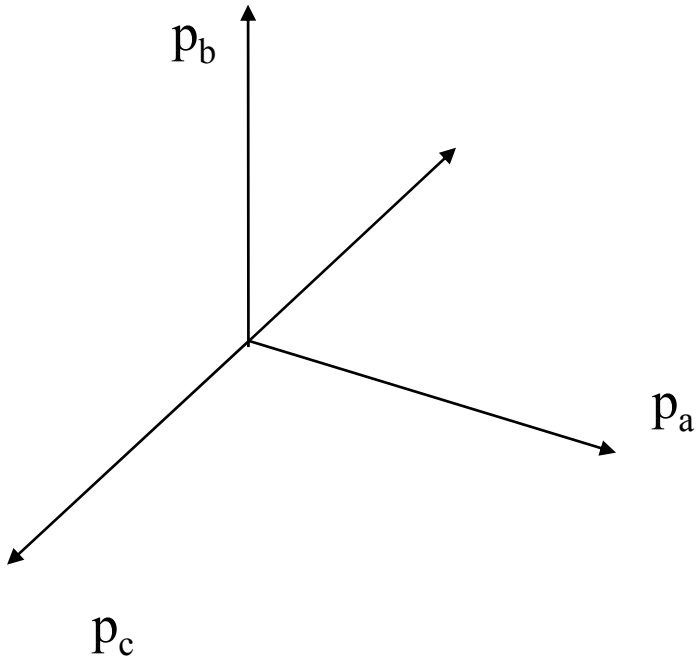
$$\vec{d}_j = (2,2)$$

$$\vec{q} = (2,1)$$



Modelo Vetorial

- Número de palavras distintas da coleção determina dimensão do espaço onde os documentos e consultas serão representados



Como determinar as coordenadas dos elementos ?

Medidas de Tf e Idf

- Idf tenta expressar a importância de uma palavra dentro de uma coleção(o quão significante é o fato da palavra ocorrer em um documento).

N: número total de documentos de uma coleção

n_t*:* número de doumentos onde a palavra t ocorreu

$$Idf(t) = \log\left(\frac{N}{n_t}\right)$$

Quanto mais rara a palavra, maior seu idf !

Determinação das Coordenadas

$$Idf(t) = \log\left(\frac{N}{n_t}\right)$$

Coordenada do doc d no eixo t

$$w(d,t) = tf(d,t) \times idf(t)$$

Frequência da palavra t no documento d

Importância de t na coleção

Exemplo

D1	A A A B
D2	A A C
D3	A A
D4	B B

$$idf(A) = \log\left(\frac{4}{3}\right) = 0{,}28$$

$$idf(B) = \log\left(\frac{4}{2}\right) = 0{,}69$$

Exemplo

D1	A A A B
D2	A A C
D3	A A
D4	B B

$$w(D1, A) = idf(A) \times tf(D1, A) = 0{,}28 \times 3 = 0{,}84$$

$$w(D1, B) = idf(B) \times tf(D1, B) = 0{,}69 \times 1 = 0{,}69$$

$$w(D1, C) = idf(C) \times tf(D1, C) = 1{,}38 \times 0 = 0$$

$$\vec{D}1 = (0{,}84\ ,\ 0{,}69\ ,\ 0)$$

Exemplo

Para uma consulta Q composta por A e B:

$$w(Q,A) = idf(A) \times tf(Q,A) = 0{,}28 \times 1 = 0{,}28$$

$$w(Q,B) = idf(B) \times tf(Q,B) = 0{,}69 \times 1 = 0{,}69$$

$$w(Q,C) = idf(C) \times tf(Q,C) = 1{,}38 \times 0 = 0$$

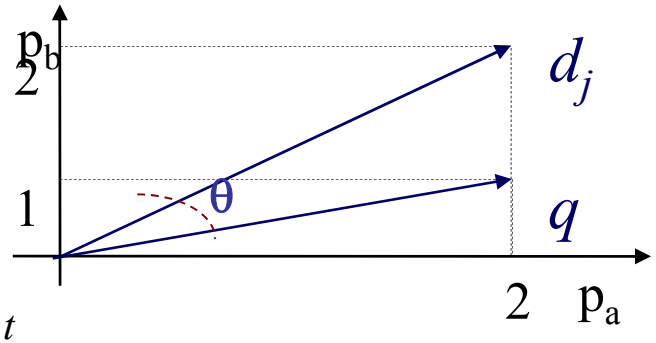
$$\vec{Q}1 = (0{,}28 \ , \ 0{,}69 \ , \ 0)$$

Similaridade

- Correlação entre dois vetores é utilizada para medir a proximidade entre os elementos reais modelados.

$$\vec{d}_j = (2,2)$$

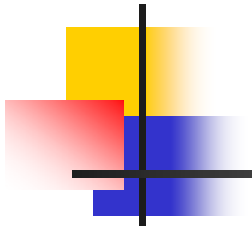
$$\vec{q} = (2,1)$$



$$sim(d,q) = \cos\theta = \frac{\sum_{i=1}^{t} w(i,d) \times w(i,q)}{\sqrt{\sum (w(i,d))^2} \times \sqrt{\sum (w(i,q))^2}}$$

Norma de d

Norma de q



Statistical Language Models

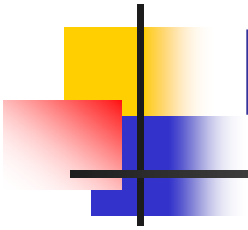
Statistical Language Models

- Language models: Mecanismos probabilísticos para modelar fontes textuais
- Aplicação inicial em compressão de dados
- Muito aplicado em reconhecimento de voz (desde a década de 70)
- Aplicado em tradutores na década de 80
- Aplicado em sistemas de busca a partir da década de 90

Statistical Language Models

- São modelos probabilísticos
- Calcula-se a probabilidade de uma consulta ser gerada por um modelo extraído a partir de um documento.

Exemplo



- Espera-se que:
  - P(“departamento de ciência da computação”|HOME DO DCC UFMG)>
  - P(“departamento de ciência da computação”|HOME DA UFMG)
- A fonte de informação HOME DO DCC tem mais chance de gerar a string do que a fonte de informação HOME DA UFMG
- Desafio é aprender o modelo que representa cada documento D para calcular P(Q|D).

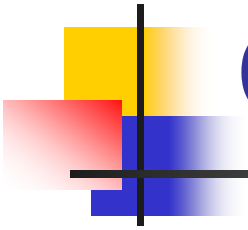
Modelo Mais simples

- Considerar cada palavra como sendo independente das demais
- $p(w_1\ w_2\ \ldots\ w_n)=p(w_1)p(w_2)\ldots p(w_n)$
- Probabilidade de uma dada consulta ser gerada por um documento:

$$P(Q=\{k_1,\ldots,k_m\}\mid D)=P(K_1\mid D)\times\ldots\times P(K_m\mid D)$$

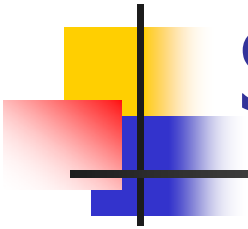
- Onde K_i é um termo de Q e m é o número de termos

Como estimar P(K|D) ?

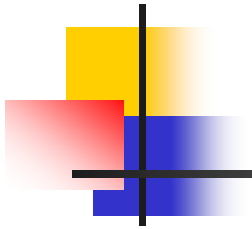


- Pode-se contar número de ocorrências de K em D e dividir pelo total de palavras em D:
- Ex: K aparece 10 vezes de um total de 100 palavras em D: P(K|D)=0,1
- Problemas com essa abordagem ???

Suavização (smoothing)

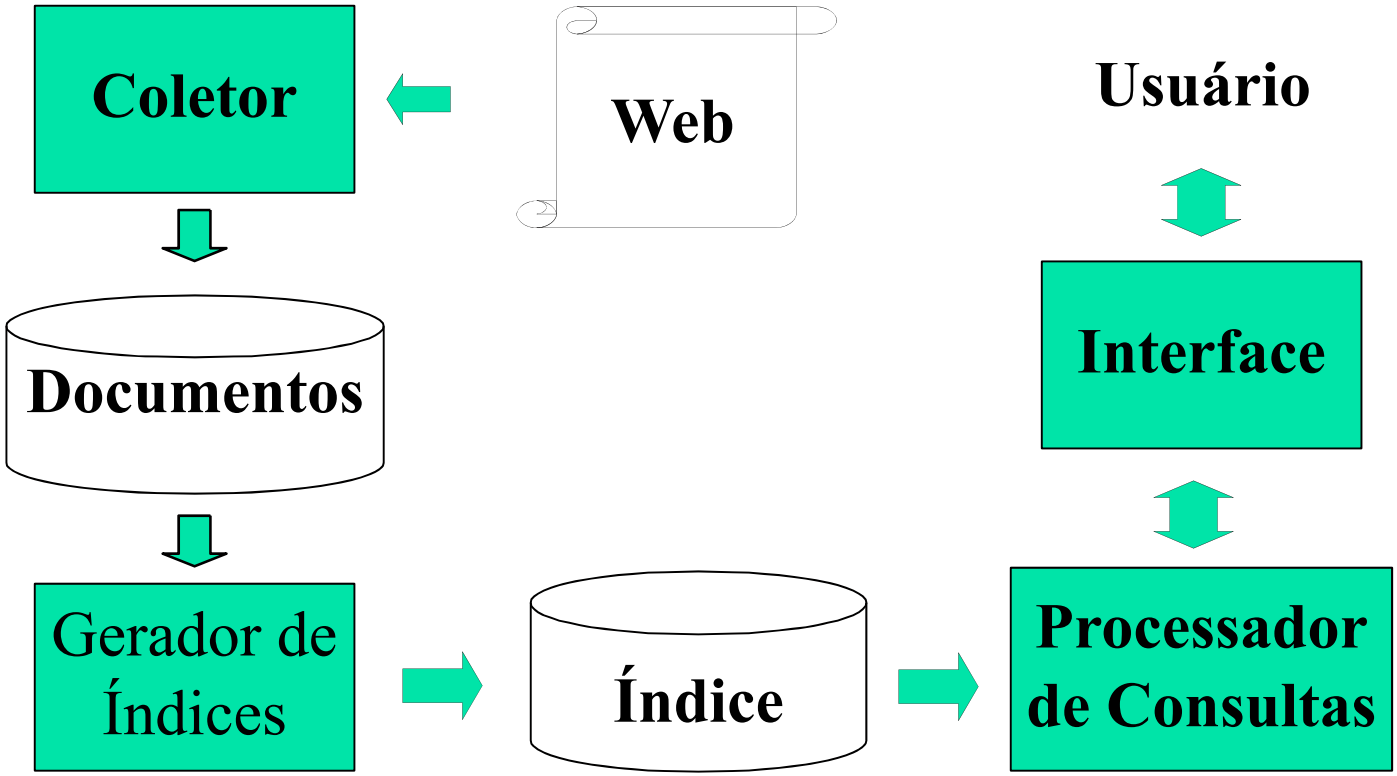


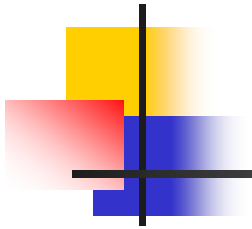
- Se uma palavra não aparece no documento, sua probabilidade não deve ser 0!
- Se uma palavra da consulta não aparece em D então P(Q|D) = 0 ?
- Solução é fazer uma suavização no modelo. Há diversas propostas na literatura!(ex. somar uma constante à freqüência)
- Esquemas acabam resultando em equações com componentes bem parecidos com as do modelo vetorial



3. Implementação de Sistemas de Busca para a Web

Arquitetura

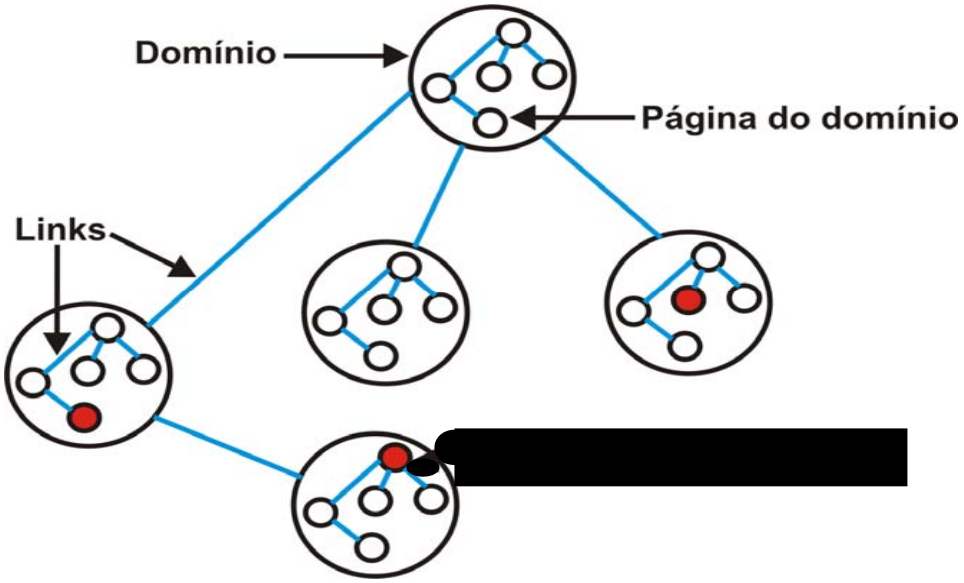


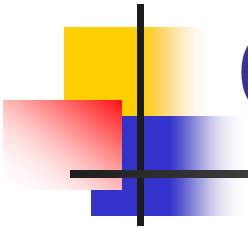


Coletor

Coletor

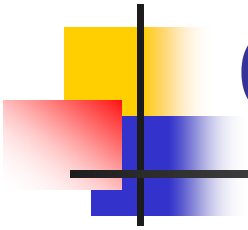
- Processo de se navegar entre páginas www usando estrutura de hyperlinks.
- A estrutura de hyperlinks da web pode ser modelada como um grafo.





Coletores

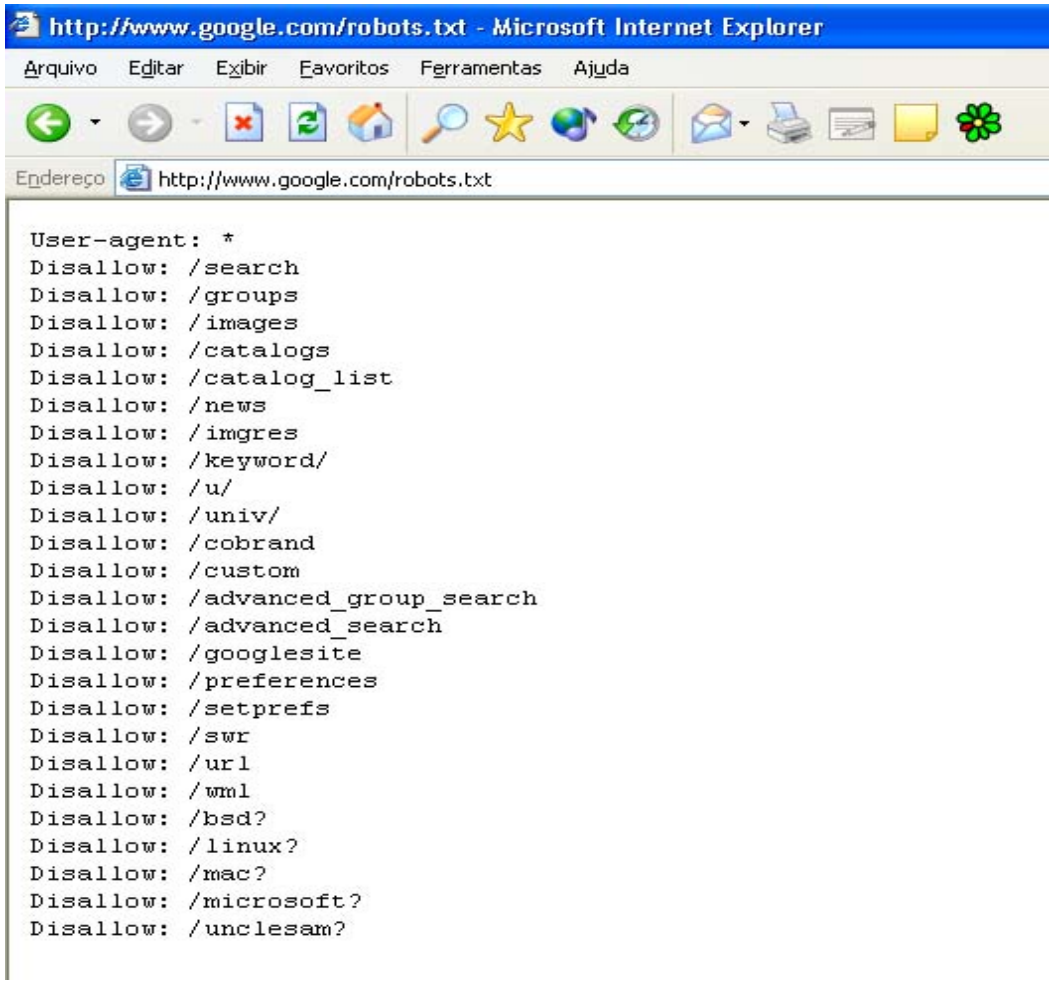
- Navegadores automáticos entre páginas web que visam armazenar uma cópia local das páginas encontradas
- Devem obedecer algumas restrições ao visitar sites.
- O Protocolo de Exclusão de Robôs (Robot Exclusion Protocol) especifica algumas regras de acesso.
  - Principal regra é não deixar um intervalo de tempo entre acessos a cada servidor.



Coletores

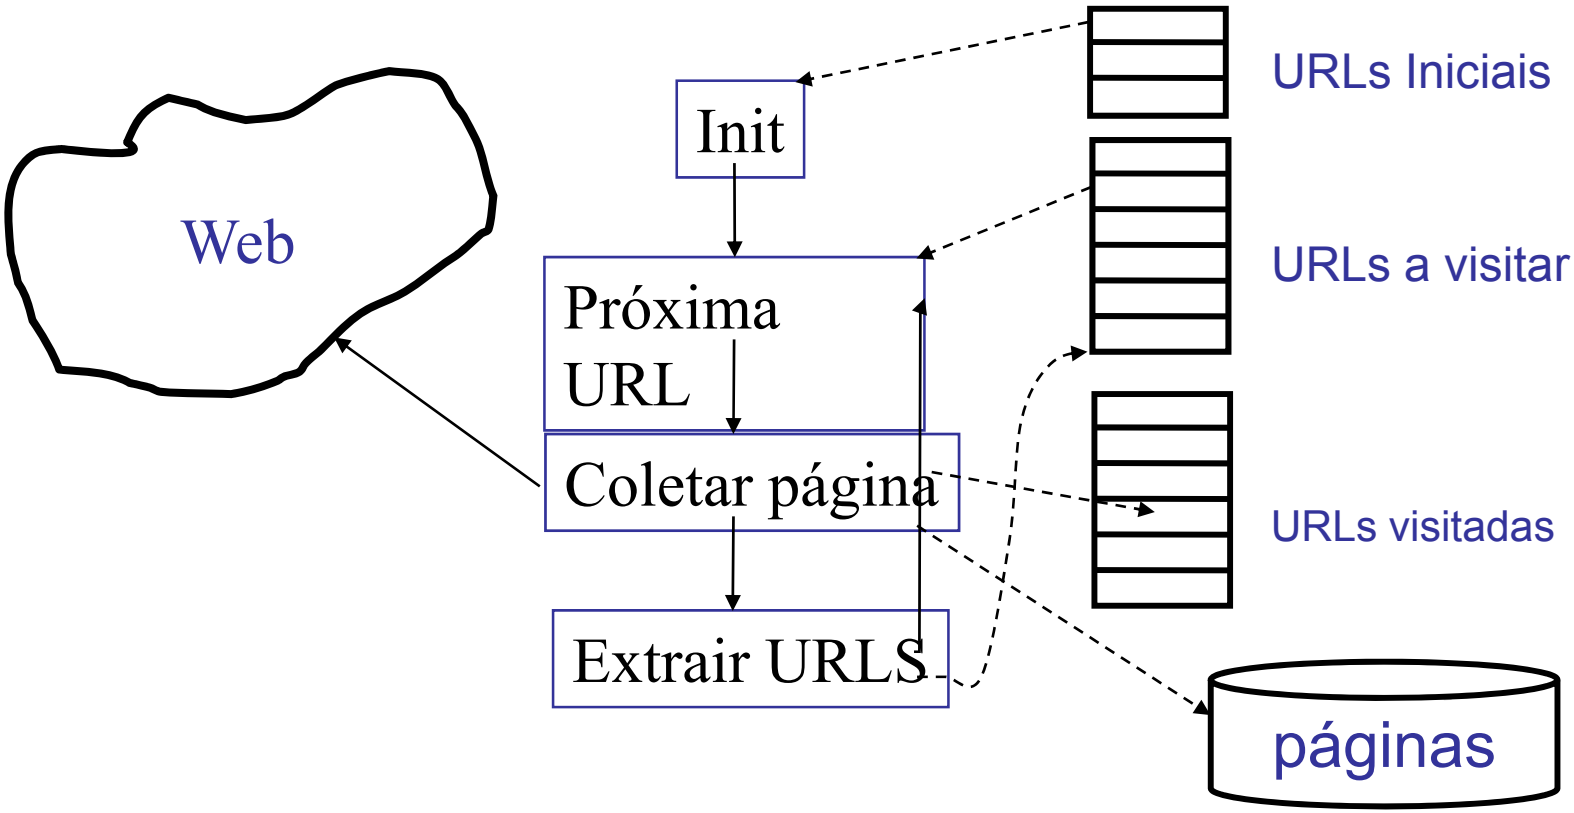
- O Protocolo de Exclusão de Robôs:
  - Padrão definido em 30 de junho de 1994.
  - Define as permissões do *coletor* em um determinado site.
  - As diretrizes são descritas em um arquivo chamado "robots.txt", localizado no servidor web coletado.

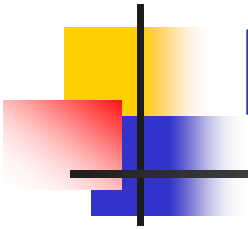
Exemplo de robots.txt



Coletor

- Esquema gráfico do funcionamento de um coletor.

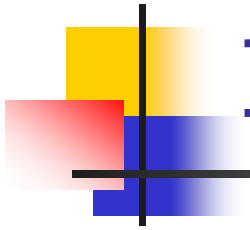




Escalonamento

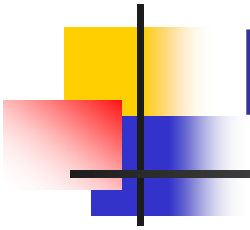
- Páginas devem ser coletadas seguindo métricas de importância
- Métricas devem definir prioridade de coleta e refrescamento de página
- Objetivo final deve ser maximizar a qualidade das respostas providas pela máquina de busca

Exemplos de Métricas de Importância

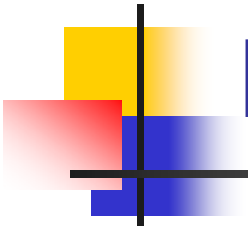


- Exemplo:
  - Número de Links de Entrada e Saída
  - Número de vezes que página foi mostrada como resposta a usuários

Forma de escalonamento

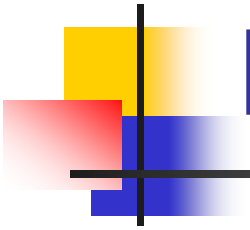


- Fila de prioridades para coleta é ordenada periodicamente fora do sistema de coleta
- Algumas URLs podem ter preferência no escalonamento
  - Ex.: Páginas de entrada em portais de notícias



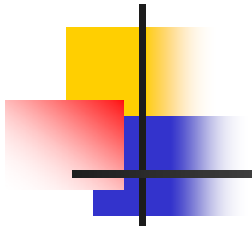
Desafios de Projeto

- Desafios ao se projetar um coletor:
  - Definir a periodicidade de atualização das páginas (Freshness) X Encontrar novas url's.
  - Usar o máximo de largura de banda sem sobrecarregar os *sites* visitados.
  - Identificar páginas redundantes (Réplicas).
  - Coletar "boas" páginas.



Problemas práticos

- Sobrecarga do DNS
- Erros de acesso repetido a servidores
- Extração de links pode gerar URLs falsas ou links infinitos
- Coleta de páginas dinâmicas
- Normalização de URLs
- Diferença de velocidade entre servidores pode afetar velocidade
- ... (há muitos outros problemas)



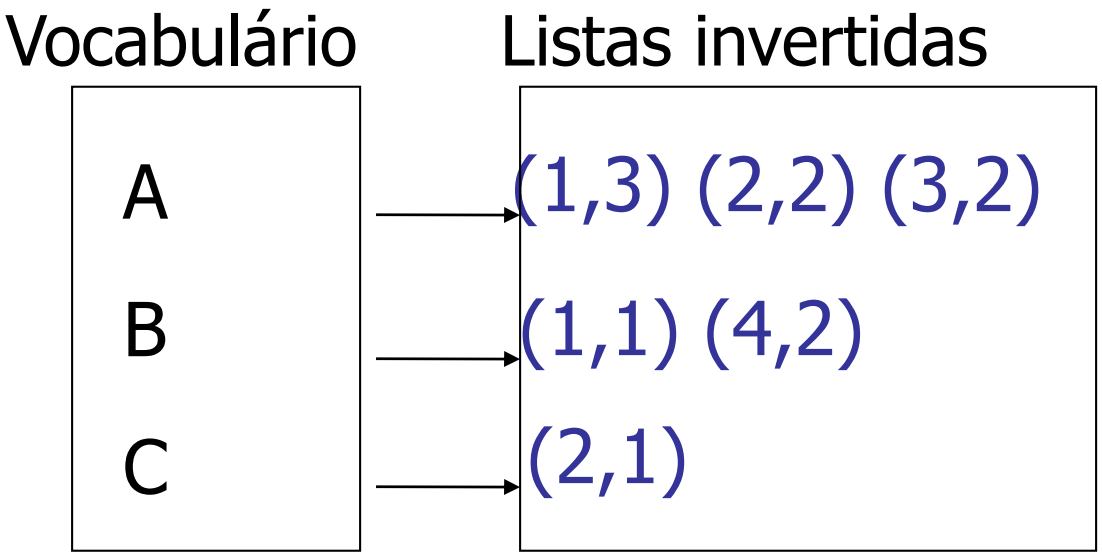
INDEXAÇÃO

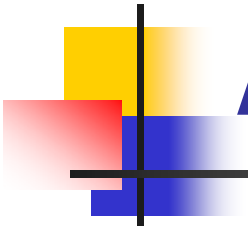
Estrutura de Dados: Arquivo Invertido

- Composto de:
  - Vocabulário - contém cada termo (t) distinto da coleção;
  - Listas Invertidas - Para cada termo da coleção há uma lista invertida que indica a freqüência com que o termo ocorre em cada documento da coleção;

Estruturas de Dados: Arquivo Invertido

D1	A A A B
D2	A A C
D3	A A
D4	B B

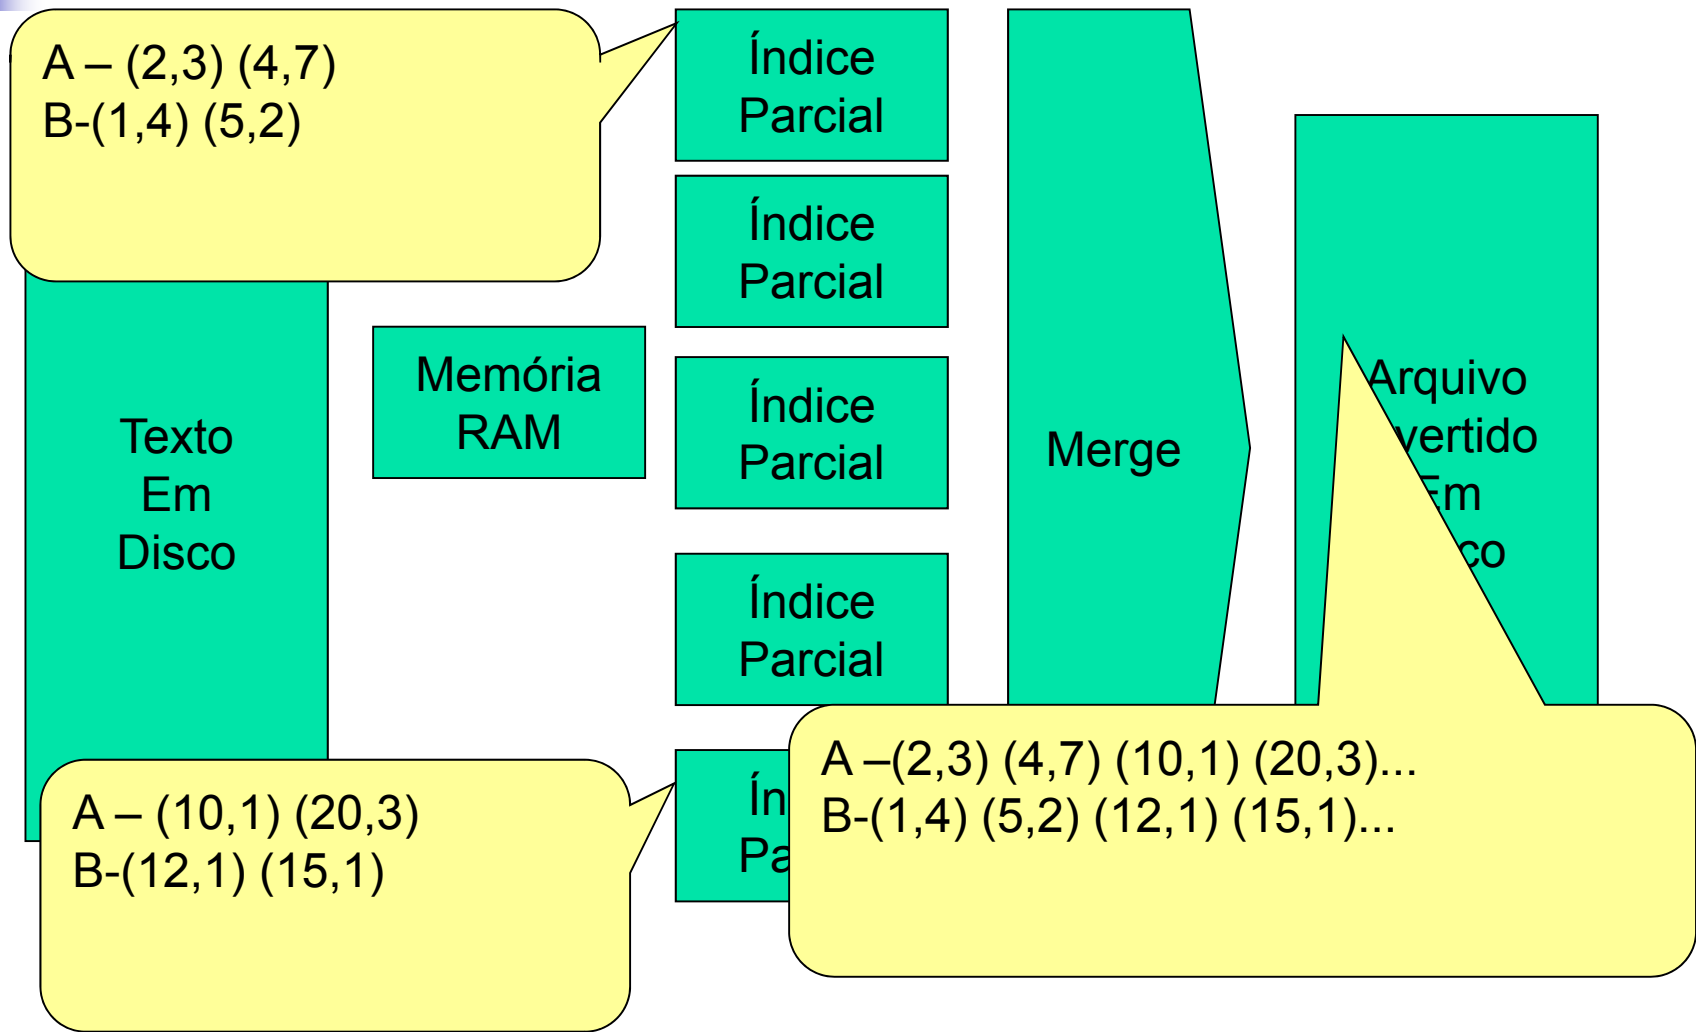


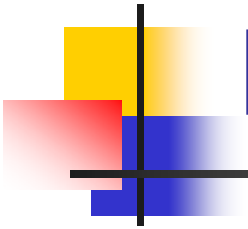


Arquivos Invertidos

- Construção:
  - Fácil de construir quando há memória RAM suficiente;
  - Algoritmos mais sofisticados são necessários quando a base de dados é muito grande;

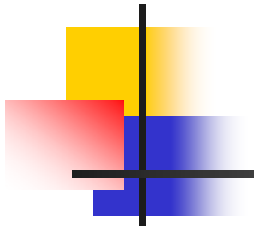
Construção de arquivos invertidos





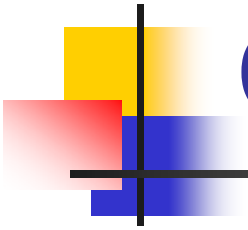
Merge

- Merge utiliza memória como buffer para acelerar o processo de indexação
- Compressão de dados pode ser usada para reduzir o tamanho dos índices e assim aumentar a velocidade de indexação

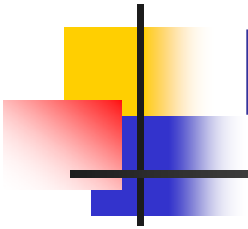


PROCESSAMENTO DE CONSULTAS (MODELO VETORIAL)

Processamento de Consultas(Vetorial)



- Vocabulário e listas invertidas em disco;
- Cache para acesso aos dados
- Idf dos termos e normas dos documentos são pré-computados;
- Custo de manter o vocabulário em disco não é proibitivo



Processamento de Consultas

- Durante o processamento de consultas devem ser computadas as similaridades entre o vetor da consulta e os vetores de cada documento da coleção.
- Os pesos dos documentos são calculados na medida em que as listas invertidas são processadas.

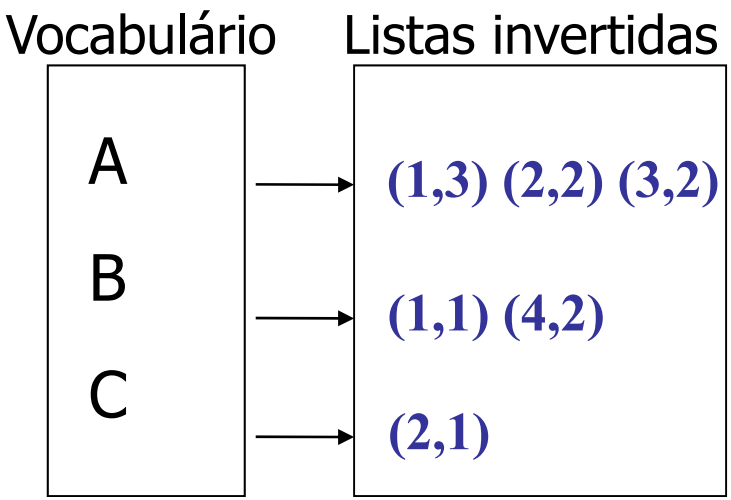
Processamento de Consultas

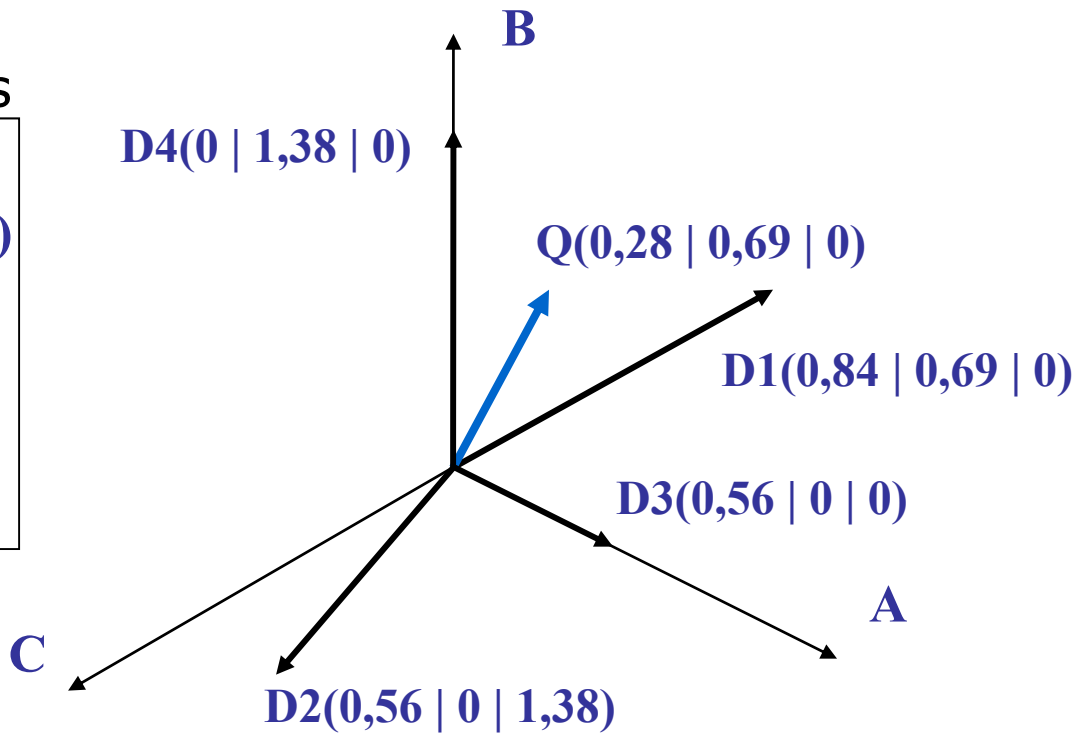
- Simplificações que aceleram o processamento:
  - Documentos que não possuem os termos das consultas têm similaridade igual a zero;
  - O co-seno é calculado de maneira que se possa ler as listas invertidas seqüencialmente durante o cálculo;

Estruturas de Dados: Arquivo Invertido

Q = "A B"

D1	A A A B
D2	A A C
D3	A A
D4	B B



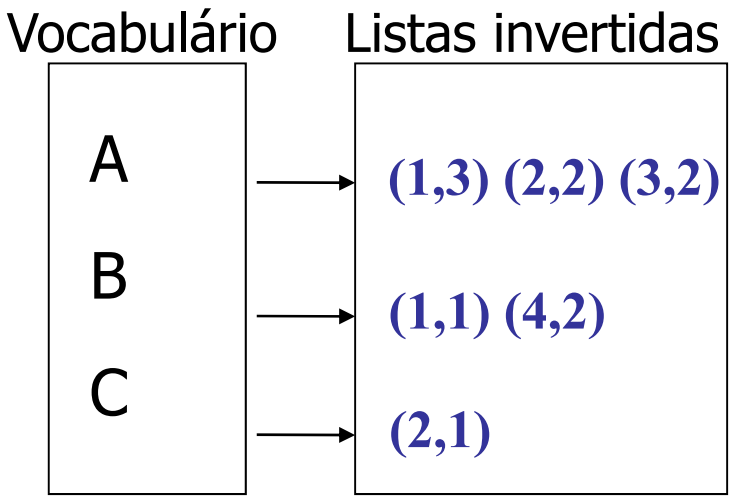


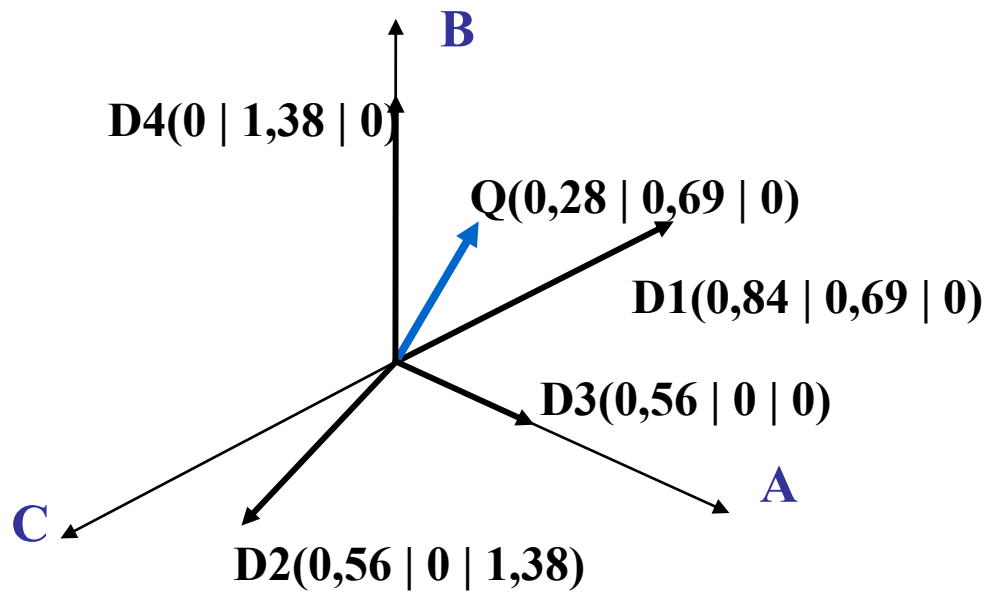
Acumuladores para cálculo da similaridade parcial

Acumuladores:

D1	D2	D3	D4
0	0	0	0

$$sim_parc(q,d,t) = w(d,t) \times w(q,t)$$



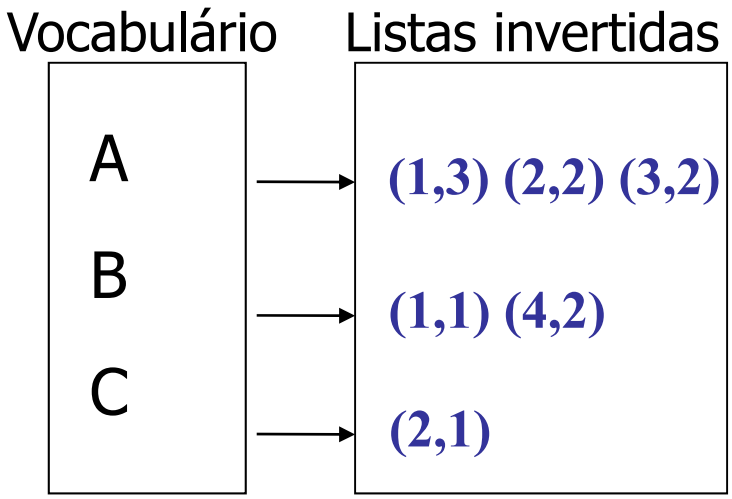


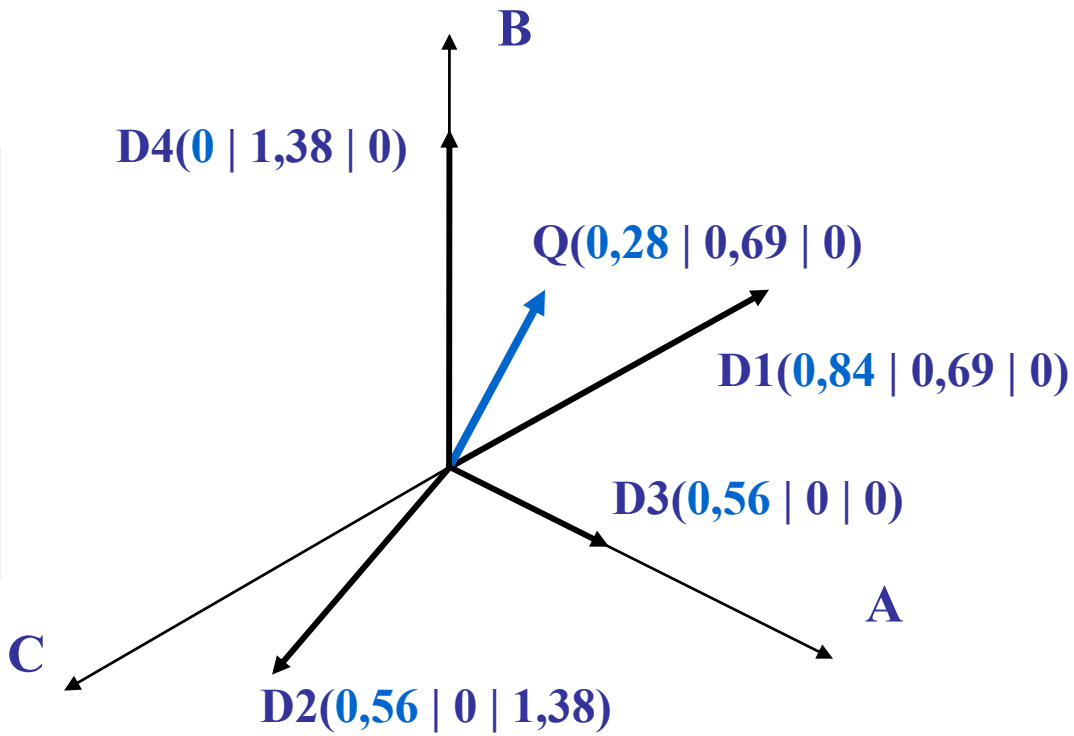
Acumuladores para cálculo da similaridade parcial

Acumuladores:

D1	D2	D3	D4
0,24	0,16	0,16	0

$$sim_parc(Q, D1, A) = w(D1, A) \times w(Q, A) = 0{,}84 \times 0{,}28 = 0{,}24$$

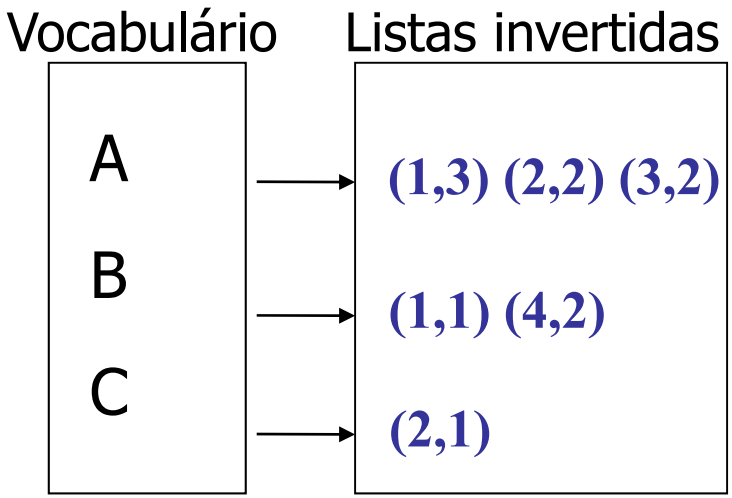


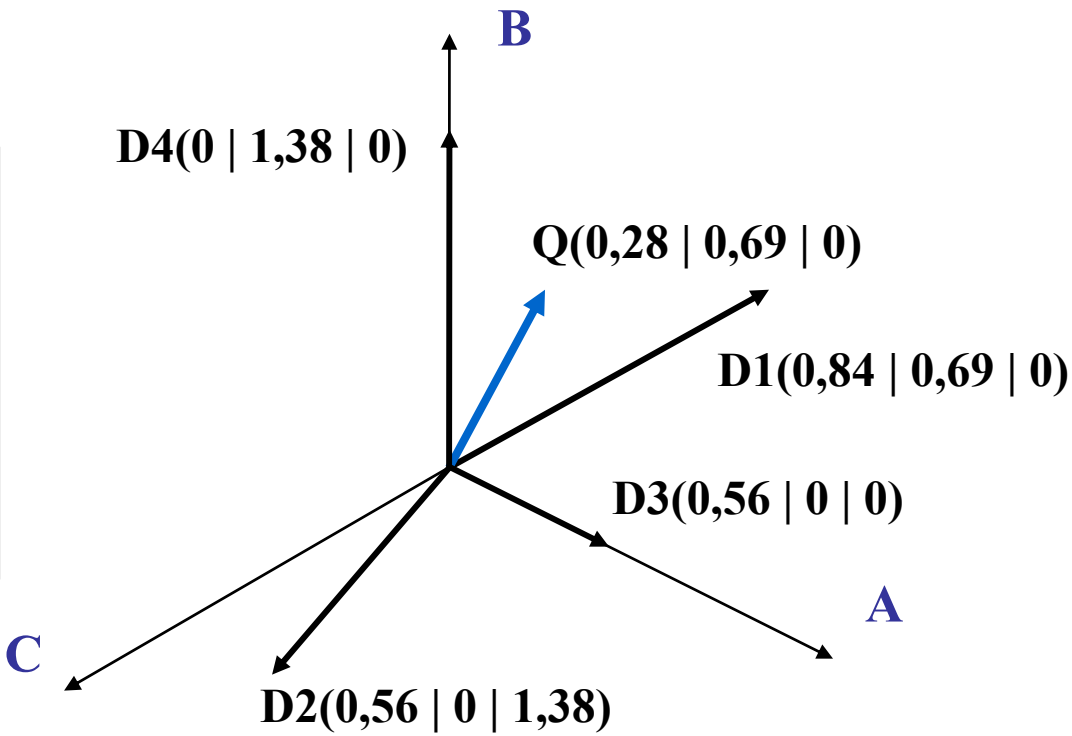


Acumuladores para cálculo da similaridade parcial

Acumuladores:

D1	D2	D3	D4
0,71	0,16	0,16	0,95





Acumuladores para cálculo da similaridade parcial

Acumuladores:

D1	D2	D3	D4
0,71	0,16	0,16	0,95

$$sim(d,q) = \cos\theta = \frac{\sum_{i=1}^{t} w(i,d) \times w(i,q)}{\sqrt{\sum (w(i,d))^2} \times \sqrt{\sum (w(i,q))^2}}$$

Norma do documento

Norma da consulta

Acumuladores para cálculo da similaridade parcial

$$norma(d1) = \sqrt{\sum (w(i,d1))^2} = \sqrt{(0{,}84)^2 + (0{,}69)^2} = 1{,}08$$

$$norma(d2) = 1{,}49$$

$$norma(d3) = 0{,}56$$

$$norma(d4) = 1{,}38$$

Acumuladores para cálculo da similaridade parcial

Acumuladores:

D1	D2	D3	D4
0,71	0,16	0,16	0,95

$$norma(d1) = 1{,}08$$

$$norma(d2) = 1{,}49$$

$$norma(d3) = 0{,}56$$

$$norma(d4) = 1{,}38$$

$$sim(d1,q) = \frac{Acum(d1)}{\|\vec{d}1\| \times \|\vec{q}\|} = \frac{0{,}71}{1{,}08 \times \|\vec{q}\|} = \frac{0{,}66}{\|\vec{q}\|}$$

$$sim(d2,q) = \frac{0{,}16}{1{,}49 \times \|\vec{q}\|} = \frac{0{,}17}{\|\vec{q}\|}$$

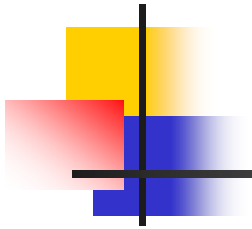
$$sim(d3,q) = \frac{0{,}16}{0{,}56 \times \|\vec{q}\|} = \frac{0{,}28}{\|\vec{q}\|}$$

$$sim(d4,q) = \frac{0{,}95}{1{,}38 \times \|\vec{q}\|} = \frac{0{,}69}{\|\vec{q}\|}$$

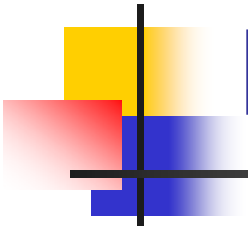
Algoritmo

1. Para cada documento d na coleção, criar $A[d] = 0$.
2. Para cada termo t na consulta,
   (a) Recuperar a lista invertida para o termo t do disco.
   (b) Para cada entrada $\langle d, f(d,t) \rangle$ na lista invertida,
   $$A[d] = A[d] + sim(q,d,t)\,\$.$$
3. Dividir cada acumulador $A[d] \neq 0$ pela norma do documento $|\vec{d}|$.
4. Identificar os k valores mais altos de acumuladores, onde k é o número de documentos retornados para o usuário.

Figura 3: Algoritmo para o cálculo da similaridade no modelo vetorial.



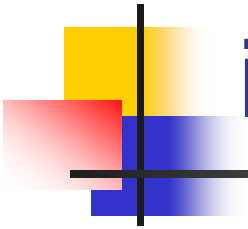
4. Ranking na Web



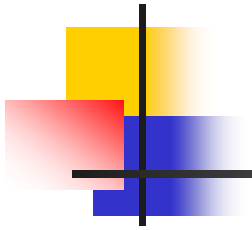
Ranking na Web

- A qualidade das respostas em sistemas de busca para a Web pode ser melhorada utilizando-se diversas fontes de informação

Exemplos de fontes de informação para a Web



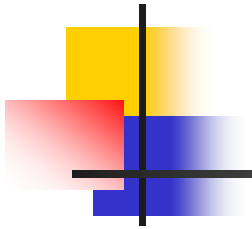
- Objetivo do usuário
- Reputação de páginas
- Concatenação de âncoras
- Nível das Urls
- Texto das Urls
- Click nas respostas
- Formatação das páginas
- Outras possibilidades...



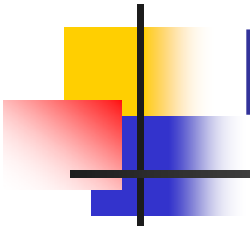
Objetivos do Usuário

Tipos de consultas de acordo com objetivos dos usuários

- Informacionais - Interessado em buscar informação sobre um tema, não importa onde(cerca de ½ das consultas)
- Navegacionais – Interessado em encontrar uma página específica (cerca de 1/3 das consultas)
- Transacionais – Interessado em efetuar uma transação
- Outros tipos....



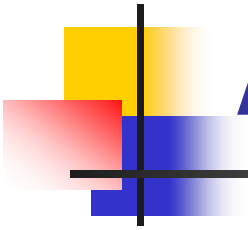
Reputação das Páginas



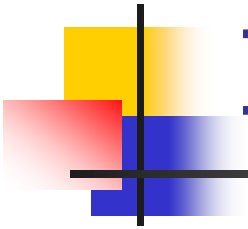
Reputação das páginas

- Links podem ser considerados como indicadores de qualidade para uma página
- Reputação da página na Web pode ser estimada através da estrutura de links

Alguns exemplos de métodos

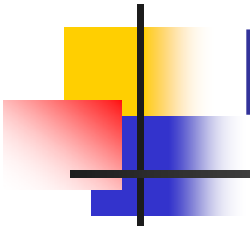


- Indegree (96)
- Pagerank (97)
- Diversas variações....



Indegree

- Conta o número de apontadores para uma dada página
- Possíveis variações incluem número de domínios, hosts e etc...



Pagerank

- Tenta estimar a probabilidade de um usuário chegar em uma página durante um caminhamento aleatório

Pagerank

- *A importância de uma página P é dada pela seguinte equação:*

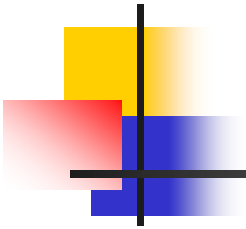
  - $PR(p) = (1-d) + d\ (\ PR(t_1)/c_1 + \ldots + PR(t_n)/c_n)$

  d – dump factor (geralmente entre 0.1 e 0.9)

  T_i *– página que aponta para P*

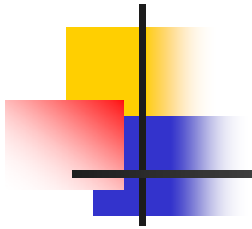
  c_i *– quantidade de links em* T_i

- *Pagerank procura expressar a probabilidade de uma página P ser acessada.*



Pagerank

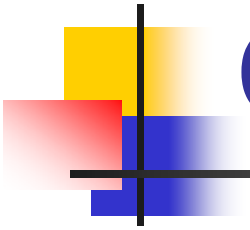
- Menos suscetível a ataques do que Indegree
- Dá mais importância a apontadores oriundos de páginas com boa reputação
- Evita que páginas com muitos apontadores tenham influência muito alta nos resultados



Texto de âncora

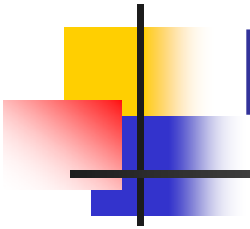
Concatenação de âncoras

- Representa cada página P com a concatenação de todos os textos utilizados em apontadores para P na Web
- Fonte de evidência textual que pode ser usada com modelos de RI similares aos de texto



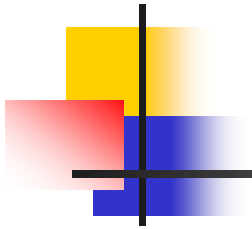
Questões importantes

- Apontadores internos devem ser levados em consideração ?
- Pode ser facilmente burlado!
- Como tornar esta fonte de evidência segura ?

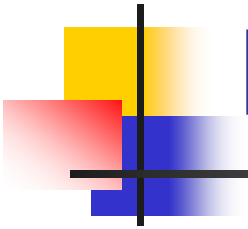


Propriedades interessantes

- Captura as diversas formas de descrever o conteúdo de uma página
- Serve para diminuir Gap entre vocabulário de quem formula a consulta e de quem escreve o texto
- Permite a descrição de conteúdos em páginas que não possuem texto

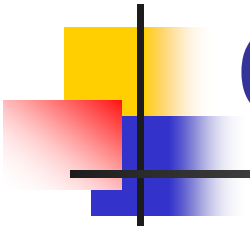


Nível da URL



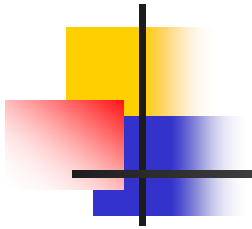
Nível da URL

- Atribui a cada página um nível de acordo com sua profundidade na estrutura de diretórios de um site
- Tem boa correlação com métodos para estimar reputação de páginas
- Serve como fonte de informação para distinguir páginas que não possuem reputação

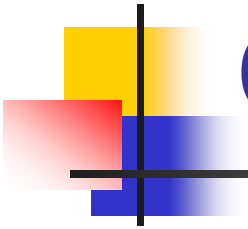


Questões importantes

- O que fazer com sites que não utilizam estrutura de diretórios ?
- Agrupa páginas em poucas categorias
- Poderíamos utilizar um nível virtual em função do número de apontadores seguidos a partir da homepage do site ?

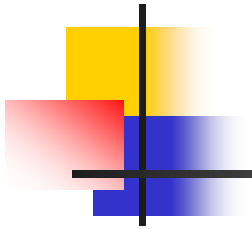


Clique nas respostas



Click nas páginas

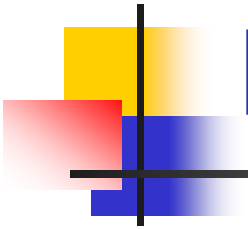
- Páginas mais seguidas em respostas podem ter seu ranking melhorado
- Não há modelo padrão para o uso dessa informação
- Pode ser usado para pequenas modificações no ranking
- Deve ser usado com cuidado



Como combinar tantas fontes de informação ???

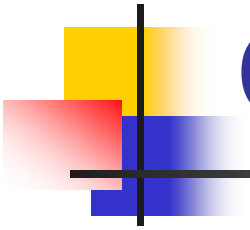
Como combinar fontes ?

- Costumava-se normalizar resultados e assumir independência entre fontes
- Exemplos: Combinações lineares ou tratamento probabilístico
- Fala-se em percentual de impacto para cada fonte (não há artigos descrevendo idéia)
- Problema é mais complicado...



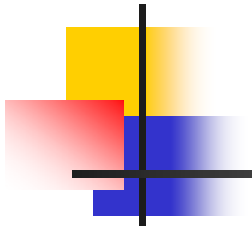
Problemas com combinação

- Fontes nem sempre são independentes
- Diferenças entre pesos pode não ser linear
- Combinação pode mudar de acordo com tipo de consulta
- Como utilizar evidências independentes de consulta (Pagerank, Nivel de URLs e etc...) ?



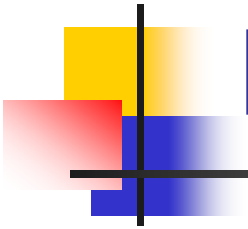
Como combinar fontes...

- Um caminho que tem sido estudado ultimamente é o uso de algoritmos de aprendizagem automática
- Ex.: Uso de Programação Genética na combinação de fontes de evidências



5. Avaliação de Sistemas de RI

Avaliação de Sistemas de Busca



- N – conjunto de documentos relevantes identificados pelos especialistas
- R – conjunto de documentos respondidos pelo sistema que foram examinados.

Precisão e Revocação

$$\text{Precisão} = \frac{|N \cap R|}{|R|}$$

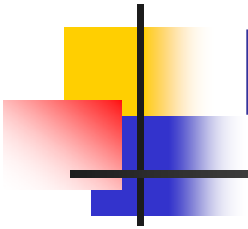
concentração de relevantes entre os documentos dados como resposta

$$\text{Revocação} = \frac{|N \cap R|}{|N|}$$

Percentual do total de relevantes

Curva de Precisão e Revocação

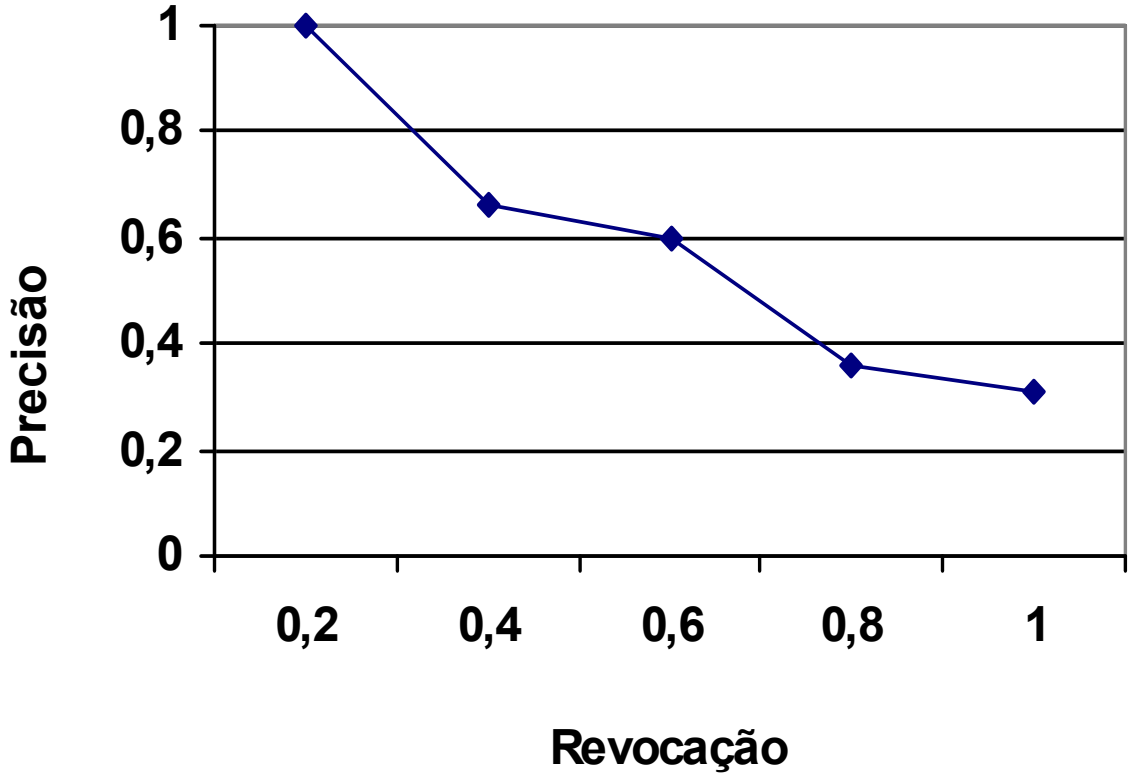
- Para facilitar a avaliação dos resultados é traçado um gráfico que mostra a evolução da precisão em função da revocação.
- Gráfico é conhecido como curva de precisão e revocação.



Exemplo

- Documentos relevantes: {1, 4, 8, 44, 72}.
- Um sistema recupera o vetor resultado: <8, 22, 72, 3, 1, 2, 24, 6, 33, 45, 4, 48, 55, 32, 11, 44>.
- O nível de revocação 20% é atingido quando encontramos o primeiro documento relevante (8), a precisão é de 1/1 = 100%.
- Para revocação de 40% a precisão é igual a 2/3 = 66%.

Curva de Precisão e Revocação

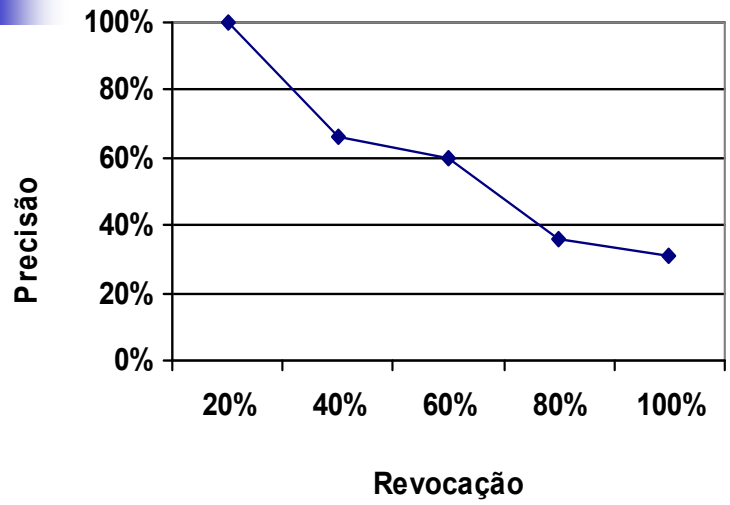


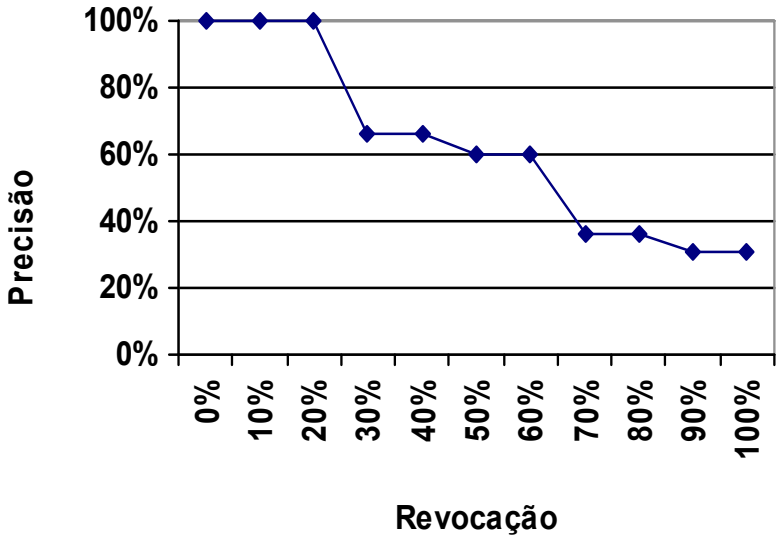
Precisão média

- Normalmente é interessante que se faça a avaliação do sistema utilizando-se uma média das precisões obtidas em várias consultas
- Pontos de precisão conhecidos são diferentes para cada consulta
  - Solução é criar uma forma de se ter valores conhecidos nos mesmos pontos em todas as consultas.

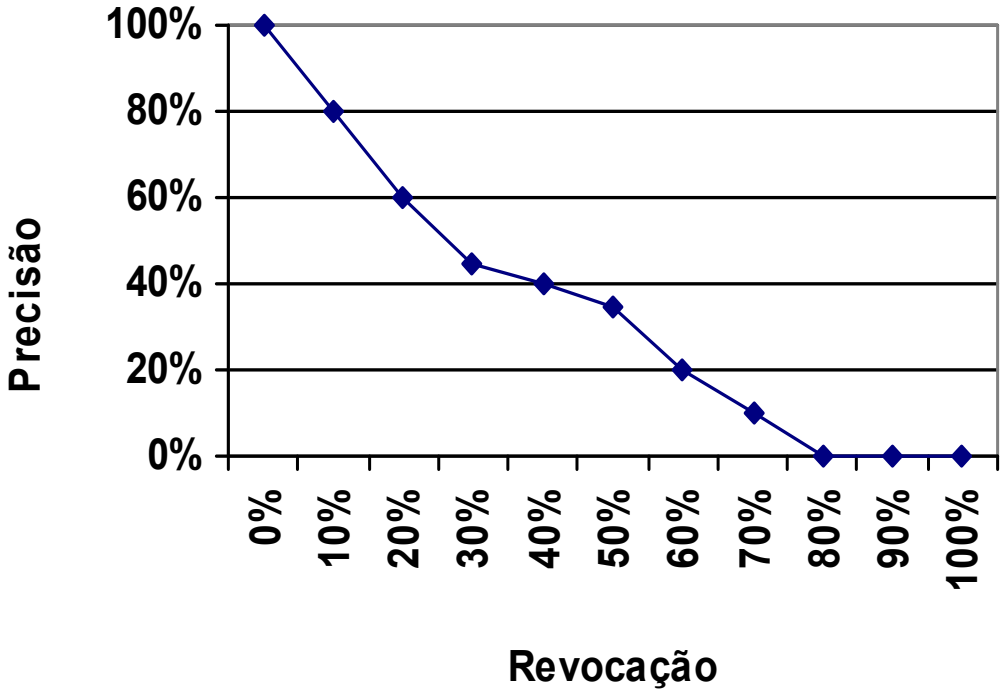
Precisão nos 11 pontos

- Utiliza-se um método de interpolação para se obter a precisão em 11 pontos de revocação (0%, 10%, 20%, ...,100%)
- Interpolação é feita tomando-se a precisão máxima conhecida entre o ponto atual e o próximo. Se não houver resultado, busca-se os próximos pontos até que se tenha uma definição

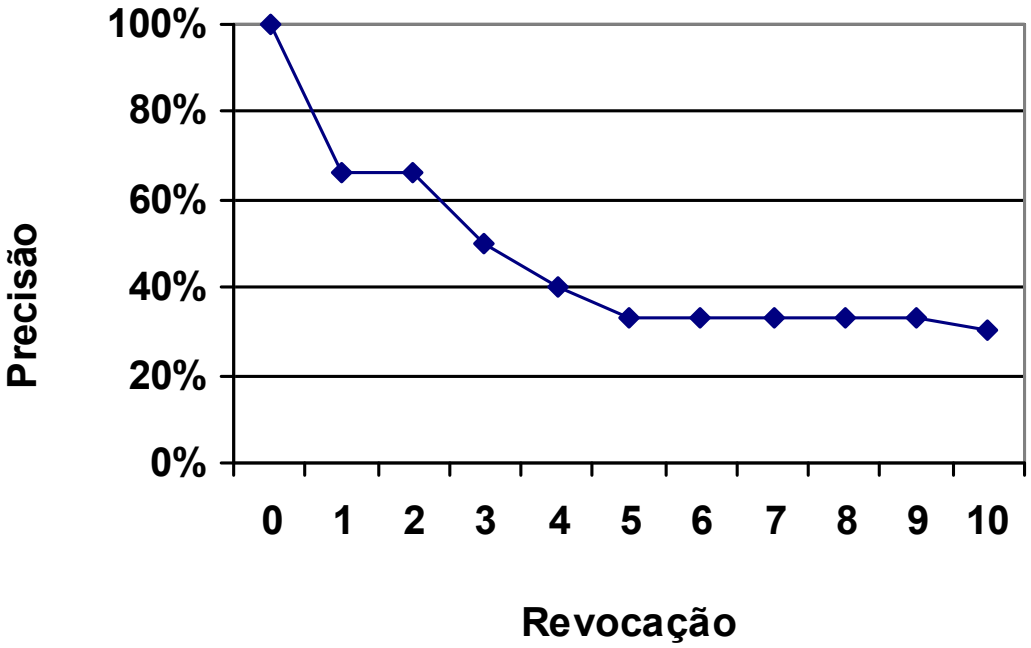

100%
80%
60%
40%
20%
0%
Precisão
20%
40%
60%
80%
100%
Revocação


100%
80%
60%
40%
20%
0%
Precisão
0%
10%
20%
30%
40%
50%
60%
70%
80%
90%
100%
Revocação

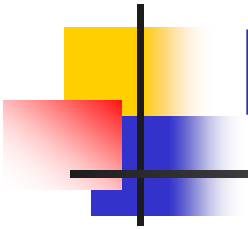
Se não recupera todos os relevantes precisão cai a zero



Precisão também pode ser computada em função do número de documentos vistos



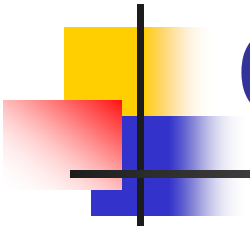
Neste caso também utiliza-se interpolação



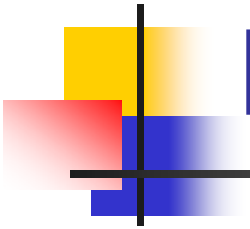
Exercício

- Documentos relevantes: {1, 4, 8, 25,44,53, 72}.
- Um sistema recupera o vetor resultado: <22, 8,72, 1, 3, 2, 25, 6, 33, 45, 4, 48, 55, 32, 11, 44>.
- Mostre a curva de precisão e revocação utililizando os 11 pontos padronizados
- Mostre o grafico de barra da precisão_X nas 10 primeiras posicoes do ranking

Calculando valores únicos



- Em alguns casos é interessante que se tenha um único valor de precisão para cada consulta
- Com este valor é possível comparar diretamente dois sistemas e determinar qual o melhor



Medidas escalares

- Precisão_R
  - Valor de Precisao na posicao R onde R eh o numero de documentos relevantes para uma determinada consulta

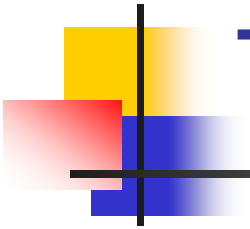
Medidas escalares

- P@X
  - Calcula-se a precisão na X-ésima posição do ranking
  - Muito utilizada quando assume-se que usuário está interessado nos X primeiros.
  - Por exemplo, nas máquinas de busca costuma-se assumir que usuário está interessado em respostas apenas entre os 10 primeiros itens

Medidas escalares

$$AP = \frac{\sum_{n=1}^{N} (P@n * rel(n))}{\#\text{ total de docs relevantes para essa consulta}}$$

$$MAP = \frac{1}{Q} \sum_{r=1}^{Q} AP_R$$

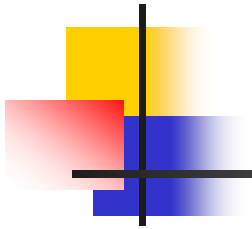


Testes estatísticos

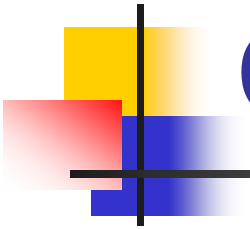
- Resultado da comparação entre dois sistemas precisa ser confiável
- Avaliação é feita com um número pequeno de consultas (tipicamente entre 30 e 50).
- Quando a diferença de valores (MAP, ou qq escalar) é pequena, o resultado pode ser considerado como não conclusivo.
- Testes estatísticos de significância devem ser empregados nestes casos

Como avaliar significância dos resultados ?

- Testes estatísticos servem para assegurar que diferença entre resultados é suficientemente grande.
  - T-test
  - Wilcoxon
- Se resultado não é significante não significa que sistemas são iguais, mas significa que o experimento não produziu uma diferença estatísticamente válida (pode-se tentar aumentar número de amostras)



6. Conclusões

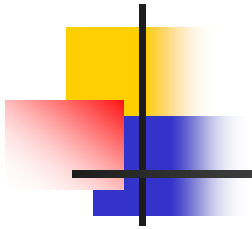


Conclusões

- Há muita teoria envolvendo o desenvolvimento de sistemas de busca modernos
- Há muito mais para aprender sobre o assunto
- Ainda há muito espaço para evolução desta área (novos resultados tem surgido a cada ano)

Onde obter mais informação ?

- Modern Information Retrieval – Berthier Ribeiro-Neto e Ricardo Baeza-Yates
- Anais do ACM SIGIR
- Anais da WWW conference
- ACM Transactions on Information Systems (ACM TOIS)
- Anais do CIKM e etc.



É ISSO!